

Tal vez...

A(Proba)rre

Transformar dudas en
Sobresalientes

Contenido

- 01** Relación de variables
- 02** Mejora de datos
- 03** Planteamiento de problema
- 04** Modelos entrenados
- 05** Comparación de métricas
- 06** Comparación de errores
- 07** Obtención del mejor modelo

Datos iniciales

Hours_Studied: número de horas estudiadas por semana




Attendance: porcentaje de atención en clase

Sleep_Hours: horas de sueño

Previous_Scores: notas anteriores (media)

Tutoring_Sessions: tutorías con el profesor

Physical_Activity: horas de actividad física





Mejora de datos

- Hours_Studied: número de horas estudiadas por semana
- Attendance: porcentaje de atención en clase
- PI: nivel de involucración de los padres con los estudios de los hijos
- Previous_Scores: notas anteriores (media)
- Tutoring_Sessions: tutorías con el profesor
- AtR: nivel de acceso a los recursos de estudios



Plazza's Industries



¿Demasiada correlación?
¿Por qué ahora hay más correlación entre las mismas variables?

Planteamiento del problema



Correlación

¿Es posible crear un modelo con variables con tanta correlación entre si?




Importancia

¿Son realmente necesarias todas esas variables para hallar la nota del examen?
¿No hay ninguna que no sea necesaria?



Target

¿Me conviene más que el target sean valores del 0 al 100 y por ende un problema de regresión?
¿O debería pasarlo a 'suficiente', 'notable', 'bien', etc, y transformarlo a un problema de clasificación?



Datos


¿Cómo puedo obtener más datos en caso de necesitarlo?

Obtención y tratamiento de datos

Funciones para sacar diferentes notas en base a las variables, totalmente ajustable

Studied	Attendance	Tutoring_Sessions	Exam_Score
23	84	0	
19	64	2	
24	98	2	
29	89	1	
19	92	3	
...	...	...	
25	69	1	
23	76	3	
20	90	3	
10	86	2	
15	67	0	


```
def generate_data(n_records):  
    'Previous_Scores': np.random.randint(50, 70, n_records)  
    'Tutoring_Sessions': np.random.randint(2, 7, n_records)  
    'PI_High': np.random.choice([0, 1], n_records, p=[0.6, 0.4])  
    'PI_Low': np.random.choice([0, 1], n_records, p=[0.95, 0.05])  
    'AtR_High': np.random.choice([0, 1], n_records, p=[0.8, 0.2])  
    'AtR_Low': np.random.choice([0, 1], n_records, p=[0.8, 0.2])  
    'Exam_Score': np.random.randint(51, 61, n_records)  
    return {'data': data, 'features': features}
```



Modelos entrenados

Los modelos entrenados en búsqueda de los mejores resultados han sido:

- Linear Regression
- Lasso Regressor
- Ridge Regressor
- Polynomical Regressor
- RandomForest Regressor
- Un GridSearch con varios modelos, cuyo mejor resultado ha sido un diferente RandomForest



Comparación de métricas

Comparación de Métricas por Modelo			
0.97203	23.21423	4.81811	3.91084
0.97201	23.22710	4.81945	3.91015
0.98031	16.33966	4.04223	3.25380
0.97201	23.22674	4.81941	3.91030
0.97051	24.47011	4.94673	4.03522
0.98022	16.41252	4.05124	3.27976
R ²	MSE	RMSE	MAE

LassoR


Pol_reg

RandomForest de GridSearch

RidgeR

Linear_reg



RandomForest



**Mejor modelo a priori:
RandomForestGS**




Comparación de MAE




Comparación de R^2

Comparación de errores




Por lo que tal vez, pese a que tienen las mejores métricas, no sea el mejor modelo si buscamos que sea resistente a outliers


Observamos que los errores de los RandomForest, se dispersan bastante más de lo que lo hacen el resto de modelos



Comparación de errores



APE
Absolute
Percentage
Error




Obtención del mejor modelo

01 ¿RandomForest?

Visto que los RandomForest son los que mejor se ajustan al test impuesto, y el resto de modelos se ajusta un poco peor, pongámoslos a prueba.



02 Outlayers



Ya que la mayoría de datos propuestos han sido creados mediante funciones estáticas, sin tener en cuenta outlayers, comprobemos qué tal se ajustan a dichos parámetros.

02 Valores

Los valores serán 20 horas de estudio, 0 atención, 0 en los exámenes anteriores, 3 tutorías, alto involucramiento de los padres

Log_reg

```
array([14.08384369])
```

RidgeR

```
array([28.38323072])
```

LassoR

```
array([30.84596919])
```

Pol_reg

```
array([28.84158325])
```

RForest

```
array([6.80470833])
```



Plazza's
Industries

Gracias

Contáctenos



Teléfono
912737658456



Mail
elmejor@modelo.delmundo



Web
www.github.com/PlazzaA

